

# 집단유전학

2026-09-30 김시환

# 새로운 HLA 대립유전자의 운명


- 돌연변이의 운명: 확산/소멸
  - 흡수벽 도달 시뮬레이션
- Selection pressure
  - Sickle cell vs. HLA
- 유효집단크기
  - effective population size,  $N_e$
  - $N_e$  추정 시뮬레이션

# AI disclaimer

- AI 기반 시뮬레이션
  - 논의 문장 생성
  - 시뮬레이션 프로그램 생성
  - 계산 결과 생성
- **수리적 이해**를 돕기 위함

# 돌연변이의 운명: 확산/소멸

- 새롭게 발생한 단일 돌연변이
- 집단 유전학의 핵심 주제 중 하나
  - 집단 내에 확산 vs. 초기에 소멸



# Sewall Wright, Ronald Fisher

## EVOLUTION IN MENDELIAN POPULATIONS

SEWALL WRIGHT

*University of Chicago, Chicago, Illinois*

Received January 20, 1930

### TABLE OF CONTENTS

|                                                                          | PAGE |
|--------------------------------------------------------------------------|------|
| Theories of evolution.....                                               | 97   |
| Variation of gene frequency.....                                         | 100  |
| Simple Mendelian equilibrium.....                                        | 100  |
| Mutation pressure.....                                                   | 100  |
| Migration pressure.....                                                  | 100  |
| Selection pressure.....                                                  | 101  |
| Equilibrium under selection.....                                         | 102  |
| Multiple allelomorphs.....                                               | 104  |
| Random variation of gene frequency.....                                  | 106  |
| Rate of decrease in heterozygosis.....                                   | 107  |
| The population number.....                                               | 110  |
| The distribution of gene frequencies and its immediate consequences..... | 111  |
| No mutation, migration or selection.....                                 | 111  |
| Nonrecurrent mutation.....                                               | 116  |
| Reversible recurrent mutation.....                                       | 121  |
| Migration.....                                                           | 126  |
| Irreversible recurrent mutation.....                                     | 128  |
| Selection.....                                                           | 129  |
| General formula.....                                                     | 133  |
| The distribution curves.....                                             | 134  |
| Dominance ratio.....                                                     | 137  |
| The mean and variability of characters.....                              | 139  |
| The evolution of Mendelian systems.....                                  | 142  |
| Classification of the factors of evolution.....                          | 142  |
| Lability as the condition for evolution.....                             | 147  |
| Control of evolution.....                                                | 151  |
| Agreement with data of evolution.....                                    | 153  |
| “Creative” and “emergent” evolution.....                                 | 154  |
| SUMMARY.....                                                             | 155  |
| LITERATURE CITED.....                                                    | 158  |

Wright. Genetics. 1931;16(2):97-159.




Fig. 1 R.A. Fisher at his calculator in 1958 (courtesy of the Fisher Memorial Trust).

Bodmer et al., Heredity (Edinb). 2021;126(4):565-576.

1. 현대 통계학의 창시 (Statistics)  
피셔는 단순한 응용을 넘어 통계학을 독립된 과학적 학문 분과로 정립한 인물이다.  
  - 추론적 검정의 체계화: 모수(parameter)와 통계량(statistic)의 개념을 명확히 구분했고, 우도(likelihood) 개념, 유의성 검정 이론, 스튜던트 t-검정의 확장, 피셔의 정확 검정(Fisher's exact test) 등을 정립했다.
  - 실험계획법(Design of Experiments)의 창안: 농업 시험장(로담스태드)에서 일하면서 무작위화(randomization), 반복(replication), 교차 구축화(blocking) 원리를 확립했다. 오늘날 농업뿐 아니라 신약 임상시험의 표준이 된 체계이다.
  - 분산분석(ANOVA): '분산(variance)'이라는 용어를 처음 도입하고 데이터를 원인별 변동으로 나누어 분석하는 기법을 만들었다.
2. 진화생물학 및 집단유전학 (Evolutionary Biology & Genetics)  
다윈의 자연선택설이 멘델의 유전학과 충돌하던 시기에 수학적 도구를 활용해 둘을 완벽하게 통합했다.
  - 현대 진화 종합(Modern Synthesis)의 기반: 멘델식 입자 유전 법칙이 양적 형질(키, 지능 등)의 연속적인 변이를 어떻게 만들어내는지를 수학적으로 규명했다.
  - 여론 집단유전학 수립: 대립유전자 빈도가 자연선택, 유전적 부동(표본 오차) 등에 의해 세대를 거치며 어떻게 변화하는지 모델링했다.
  - 진화적 형질의 이론화: '자연선택의 유전적 이론' (1930)을 통해 자연선택의 기본 정리, 선택이 1%로 추정하는 메커니즘, 유성생식과 노획의 진화 동을 수학적으로 풀어냈다.

# The Wright–Fisher model

- 라이트-피셔 확산 근사
- 포커-플랑크 방정식 활용 (확산 방정식)

$$\begin{cases} u_t(x, t) = \frac{1}{2} \frac{\partial^2}{\partial x^2} (x(1-x)u(x, t)) & \text{in } (0, 1) \times (0, \infty), \\ u(x, 0) = \delta_p(x) & \text{in } (0, 1) \end{cases}$$

- 고정 확률과 소요 시간을 수학적으로 유도할 수 있음
  - 소멸 및 고정 시간 [ $2 \ln(2N)$  세대 vs  $4N_e$  세대]

# 라이트-피셔 모델 시뮬레이션

```
def simulate_wf(two_N, p0, max_gen):
    trajectory = [p0]
    curr_p = p0
    for _ in range(max_gen):
        if curr_p == 0 or curr_p == 1:
            break
        # Wright-Fisher 이항 표본추출
        k = np.random.binomial(two_N, curr_p)
        curr_p = k / two_N
        trajectory.append(curr_p)
    return trajectory

# 1) 조기 소멸(Loss) 궤적들 수집 (회색)
loss_trajectories = []
while len(loss_trajectories) < 40:
    traj = simulate_wf(two_N, p0, max_gen)
    if traj[-1] == 0:
        loss_trajectories.append(traj)

# 2) 극소수 고정(Fixation) 궤적 1개 강제 탐색 (빨간색)
fix_trajectory = None
while fix_trajectory is None:
    traj = simulate_wf(two_N, p0, max_gen)
    if traj[-1] == 1:
        fix_trajectory = traj
```

라이트-피셔 모델 대립유전자 빈도 궤적 및 흡수벽 도달 시간



# 돌연변이의 운명: 결정 요소

- 적응도에 차이가 없는 중립 돌연변이 (neutral mutation)
  - 무작위 표류인 유전적 부동 (genetic drift)
- 변이의 존속 여부
  - 수학적 조건에 의해 결정:
    - 발생 당시의 초기 빈도 ( $p_0$ )
    - 유효집단크기 ( $N_e$ )

# 5000명 vs 50명 집단에서 1개 돌연변이의 운명

## ✓ 1. 초기 빈도 비교

diploid 기준:

- 5000명 집단 → allele 수 10,000

$$p_0 = \frac{1}{10000} = 0.0001$$

- 50명 집단 → allele 수 100

$$p_0 = \frac{1}{100} = 0.01$$

즉, 작은 집단에서 초기 빈도는 **100배**나 큼.

그럼에도 불구하고 작은 집단에서 더 빨리 사라집니다.

왜냐? → 분산이 훨씬 크기 때문입니다.

# Variance

## Binomial sampling.

Binomial sampling comes up in many contexts where we make a series of random, independent draws, and each time there is a probability  $p$  of one outcome, and  $q = 1 - p$  of the other outcome<sup>141</sup>.

In WF sampling, we make  $2N$  independent draws to create the next generation. Suppose that  $k$  is the number of times we draw the derived allele. In this case, the allele frequency after one generation of sampling is  $k/2N$ , which we will refer to as  $p_1$ . The expected value of  $p_1$  (denoted  $E(p_1)$ ) is simply

$$E(p_1) = E\left(\frac{k}{2N}\right) = p, \quad (2.2)$$

meaning that *on average* the frequency in the next generation is centered on the current frequency. This doesn't tell the whole story, however, because as shown in the histograms above, the actual, observed  $p_1$  can vary around  $p$ . We can measure how much  $p_1$  varies using the **variance** of  $p_1$ . By definition, variance measures the average squared difference from the mean:

$$\text{Var}(p_1) = E[(p_1 - p)^2] \quad (2.3)$$

Using standard properties of the binomial distribution we can show that:

$$\text{Var}(p_1) = \frac{p(1-p)}{2N} \quad (2.4)$$

Notice that the variance in  $p_1$  is inversely proportional to the population size  $N$ . This makes sense: a larger population size means that you're getting a bigger sample of the allele frequency from the previous generation. Another important quantity is the **standard deviation** (SD), which is the square root of the variance, namely:

$$\text{SD}(p_1) = \sqrt{\text{Var}[p_1]} \quad (2.5)$$

$$= \sqrt{\frac{p(1-p)}{2N}} \quad (2.6)$$

<https://web.stanford.edu/group/pritchardlab/HGbook.html>

# 초기 빈도( $p_0$ )와 고정 확률

2배체 생물의 집단 크기가  $N$ 일 때 총 대립유전자 수는  $2N$ 개다. 단일 돌연변이가 출현했을 때의 초기 빈도( $p_0$ )와 고정 확률은 다음과 같다.

| 집단 크기<br>( $N$ ) | 총 대립유전자 수<br>( $2N$ ) | 초기 빈도<br>( $p_0 = \frac{1}{2N}$ ) | 이론적 고정 확률 | 1세대 분산 지표<br>( $\frac{p_0(1-p_0)}{2N}$ ) |
|------------------|-----------------------|-----------------------------------|-----------|------------------------------------------|
| 5,000            | 10,000                | 0.0001<br>(0.01%)                 | 0.01%     | $\approx 1.0 \times 10^{-8}$             |
| 50               | 100                   | 0.01 (1.0%)                       | 1.0%      | $\approx 9.9 \times 10^{-5}$             |

중립 돌연변이의 고정 확률은 초기 빈도와 동일하므로, 단일 변이 관점에서  
의 단순 고정 확률은 작은 집단이 큰 집단보다 높다.

# 집단 크기( $N$ ) 상쇄 메커니즘

## 대형 집단 ( $N$ 큼, 5000)

- 신규 유입 변이 수 ( $2N\mu$ ):

↑ (다수 발생)

- 개별 변이 고정 확률 ( $\frac{1}{2N}$ ):

↓ (약 0.01%)

- 부동 분산이 작아,  
대부분 초기 소멸

## 소형 집단 ( $N$ 큼, 50)

- 신규 유입 변이 수 ( $2N\mu$ ):

↓ (소수 발생)

- 개별 변이 고정 확률( $\frac{1}{2N}$ ):

↑ (약 1.0%)

- 강한 부동 효과로  
우연한 고정 가능

$\mu$ 가 같다면: 변이 수(↑, ↓)와 고정 확률(↓, ↑)의 상쇄

# 수학적 상쇄와 장기 치환율

$$K = 2N\mu \times \frac{1}{2N} = \mu$$


- 매 세대 신규 변이 ( $2N\mu$ )
- 개별 변이 고정 확률 ( $\frac{1}{2N}$ )
- 집단 크기 ( $N$ )가 상쇄되어 **장기 치환율 ( $K$ )**은 돌연변이율 ( $\mu$ )에만 수렴
- *참고: 종 간 분기 연대를 측정하는 분자시계 (**Molecular Clock**)의 이론적 배경*

# 새 돌연변이의 고정 확률

- 중립 돌연변이의 고정 확률( $p=1$ )은 오직 초기 빈도  $p_0$ 로만 결정된다.
  - $N=50 \rightarrow p_0 = 1/100 \rightarrow$  고정 확률 = 1%
  - $N=5000 \rightarrow p_0 = 1/10000 \rightarrow$   
고정 확률 = 0.01%
  - **작은 집단**의 새 돌연변이의 **고정 확률은 높지만** 다음 세대에 전달된 확률의 **분산이 크기** 때문에 genetic drift에 의해 금방 사라질 가능성이 더 높다.
  - **큰 집단**에서는 **고정 확률이 낮지만 분산이 작기** 때문에 천천히 사라진다. 그러나 결국은 사라진다.


# 새 돌연변이의 고정 확률

- 중립 돌연변이의 고정 확률( $p=1$ )은 오직 초기 빈도  $p_0$ 로만 결정된다.
- 바닥( $p \approx 0$ )에서 출발하여 연속적으로 증가하는 step들이 쌓이는 경로는 매우 희귀하기 때문에 결국 새로운 중립 돌연변이는 대부분 사라진다.



# 흡수벽 도달 시간의 비대칭성

라이트-피셔 모델에서 대립유전자 빈도의 변동 분산은  $\text{Var}(p') = \frac{p(1-p)}{2N_e}$  이다.  $p_0$ 는 하한 흡수벽 (0)에 극도로 가깝기 때문에 도달 시간에 비대칭이 발생한다.



| 결과            | 도달 상태             | 상<br>태 | 평균 소요 세대<br>수       | 특징                                                          |
|---------------|-------------------|--------|---------------------|-------------------------------------------------------------|
| 소멸 (Loss)     | $p \rightarrow 0$ |        | $\approx 2 \ln(2N)$ | 집단 크기가 커져도 소요 세대는 로그 스케일로만 증가하므로, 대다수의 변이는 초기 수 세대 내에 소멸한다. |
| 고정 (Fixation) | $p \rightarrow 1$ |        | $\approx 4N_e$      | 극히 낮은 확률을 뚫고 고정에 도달하는 경우, 매우 긴 세대에 걸친 부동 과정을 거친다.           |

# HLA 대립유전자의 selection pressure (1)

- HLA 돌연변이는 selection pressure가 작용하기 때문에 집단에서 사라지지 않고 공존하는 경향이 있다.
- **Balancing selection**
  - (1) **Heterozygote** advantage
    - Sickle cell anemia
      - **Selection coefficient: 0.1-0.2** [크다]
    - HLA **selection coefficient: 0.01**
      - 극단적으로 강한 선택은 아니지만 **지속적이고 누적되는 선택**이 존재함

## HLA 대립유전자의 selection pressure (2)

- HLA 돌연변이는 selection pressure가 작용하기 때문에 집단에서 사라지지 않고 공존하는 경향이 있다.
- **Balancing selection**
  - (1) **Heterozygote** advantage
  - (2) **Rare allele** advantage
    - Pathogen들의 **면역회피** 진화는 집단에서 흔한 대립유전자를 대상으로 함
    - 따라서 rare allele에 대해서는 면역회피 기전이 발휘되지 못할 가능성이 높다.  
[**HLA-B\*57/B\*27**과 **HIV-1** elite controller]
    - 병원체의 다양성은 다양한 rare allele의 공존을 가능하게 한다.

- Strong selection (가파르게 위 / 아래)




Figure 2.84: Selection and drift of alleles from starting frequencies of 0.5 in a population of  $N = 10^4$ . The left panel shows simulated trajectories for relatively strong selection ( $2Ns = 100$  in blue, and  $2Ns = -100$  in red); and neutral in gray for comparison. The right panel shows weaker selection ( $2Ns = 10$  in blue, and  $2Ns = -10$  in red).

- Weak selection (우연에 의한 '중간' 부분)

# 유효집단크기(effective population size, $N_e$ )

- 정의

- 유전적 변이가 다음 세대로 전달되는 데 기여하는 실질적인(유효) 집단 크기

| 구분    | 그냥 집단 크기 ( $N$ , Census size)           | 유효집단크기 ( $N_e$ , Effective size)        |
|-------|-----------------------------------------|-----------------------------------------|
| 정의    | 집단 내에 존재하는 모든 개체의 물리적 총합                | 라이트-피셔 모델처럼 이상적으로 작동할 때의 실질적인 유전적 집단 크기 |
| 포함 대상 | 아기, 노인, 번식 능력이 없는 개체, 자손을 못 낳은 개체 모두 포함 | 실제로 번식에 성공하여 유전자를 다음 세대에 넘겨준 기여도만 반영    |
| 주요 역할 | 생태학적 개체수 파악                             | 유전적 부동(drift)의 세기와 유전적 다양성 소실 속도 결정     |

# 유효 집단 크기(effective population size, $N_e$ )

## 관측 크기( $N$ )와 유효집단크기( $N_e$ ) 간 괴리 요인

실제 생태 집단의 전수 조사 크기(census size,  $N$ )는 이상적인 라이트-피셔 집단보다 유전적 다양성을 빠르게 잃기 때문에 대개  $N_e \ll N$  관계가 성립한다.

| 영향 요인      | 수학적 모델 및 메커니즘                                                    | $N_e$ 에 미치는 영향                                  |
|------------|------------------------------------------------------------------|-------------------------------------------------|
| 성비 불균형     | $N_e = \frac{4N_mN_f}{N_m+N_f}$                                  | 번식 참여 개체 수가 적은 성별에 의해 $N_e$ 상한이 제한된다.           |
| 번식 성공도의 분산 | $N_e = \frac{4N-2}{V_k+2}$ ( $V_k$ : 자손 수 분산)                    | 소수 개체만 후대를 남길수록( $V_k > 2$ ) 대립유전자 전달 편중이 심화된다. |
| 세대별 크기 변동  | $\frac{1}{N_e} = \frac{1}{t} \sum_{i=1}^t \frac{1}{N_i}$ (조화 평균) | 과거 일시적인 병목(bottleneck) 사건이 장기 $N_e$ 를 크게 낮춘다.   |

## 유효집단크기(effective population size, $N_e$ )

- 완전히 이론적인 라이트-피셔 균형 모델의 경우
  - Census size, effective population size가 같다( $N = N_e$ )
  - 기본 유도과정에서는  $N$  으로 두고 전개

# 유효집단크기(effective population size, $N_e$ )

- Balancing selection에서  $N_e$ 의 중요성
  - $N_e$ 가 크면 genetic drift에 의해 사라지는 시간이 길어진다
    - 선택이 장기간 누적될 여건을 제공한다.
  - Positive selection이 작용한다면 선택계수( $s$ )가 낮더라도 집단에 공존할 가능성을 높이게 됨
    - $2 N_e \times s \gg 1$

1. 선택이 drift를 이기는 기준:  $2N_e s \gg 1$

어떤 돌연변이가 무작위적인 우연(drift)에 의해 사라지지 않고 자연선택(selection)의 힘을 받아 살아남으려면 다음 조건이 만족되어야 해.

$$2N_e s \gg 1 \quad (\text{또는 } N_e s \gg 1)$$

- 만약  $2N_e s < 1$ 이면: 선택계수가 너무 약해서 그냥 '중립 돌연변이'처럼 drift에 휩쓸려 사라짐.
- 만약  $2N_e s \gg 1$ 이면: 선택압이 drift의 무작위성을 압도하여 집단 내에 확실하게 보존됨.

## 유효집단크기(effective population size, $N_e$ )

- 유효집단크기
  - HLA 대립유전자: 십만 혹은 백만
  - HbS allele: 수천 혹은 수만
- HLA 대립유전자는 HbS allele에 비해 선택계수( $s$ )는 낮지만  $N_e$ 가 크기 때문에 새로운 allele이 집단에 공존할 가능성을 높인다.
  - $s$ 가 크면 특정 allele만 강하게 유리 → 승자(allele 1개)만 남기 쉽다.

# 자연선택의 조건과 다양성 유지

| 구분                     | 선택계수<br>( $s$ )         | 장기 유효집<br>단크기 ( $N_e$ )   | $2N_e \times s$ | 진화적 결과 및 특징                                                                       |
|------------------------|-------------------------|---------------------------|-----------------|-----------------------------------------------------------------------------------|
| 낯적혈<br>구 빈혈<br>증 (HbS) | 0.1 ~ 0.2<br>(강한<br>선택) | 수천<br>~ 수만<br>(국지적<br>집단) | $\gg 1$         | 말라리아 유행 지역,<br><b>이형접합자</b> 이점<br>→ 특정 변이가<br>국지적으로<br>높은 빈도를 유지.                 |
| HLA 면<br>역 대립<br>유전자   | 약 0.01<br>(약한<br>선택)    | 수십만<br>~ 백만<br>(종 전체)     | $\gg 1$         | 선택계수는 작으나,<br>장기 $N_e$ 가 커서<br>부동(drift)에 의한<br>소실을 피함.<br><b>희귀 대립유전자</b> 이<br>점 |

# 분산 기반 $N_e$ 추정 예제

- 가상의 p 값을 설정 + 분산 계산  
→ 수학적  $N_e$  추정 시뮬레이션

측정된 A allele 빈도:

| 세대 t | A allele 빈도 $p_t$ |
|------|-------------------|
| 0세대  | 0.30              |
| 1세대  | 0.32              |
| 2세대  | 0.29              |
| 3세대  | 0.31              |
| 4세대  | 0.30              |

유전자 빈도의 분산이

$$\text{Var}(p_{t+1}) = \frac{p_t(1 - p_t)}{2N_e}$$

이 식을 이용해, 실제 데이터로 분산을 계산해서  $N_e$ 를 추정할 수 있습니다.

## ● 실제 추정:

몇 세대에 걸친 allele frequency 자료가 있다면

$$N_e \approx \frac{p(1 - p)}{2 \text{Var}(\Delta p)}$$

여기서

$$\Delta p = p_{t+1} - p_t.$$

\*가상의 p 값을 설정하여  $N_e$  추정

# 분산 기반 $N_e$ 추정

## 계산 예시 (가상 데이터)

5세대에 걸쳐 측정한 특정 대립유전자 A의 빈도( $p_t$ )가 다음과 같다고 가정한다.

| 세대 ( $t$ ) | 대립유전자 A의 빈도 ( $p_t$ ) | 세대 간 변화량 ( $\Delta p$ ) |
|------------|-----------------------|-------------------------|
| 0세대        | 0.30                  | -                       |
| 1세대        | 0.32                  | +0.02                   |
| 2세대        | 0.29                  | -0.03                   |
| 3세대        | 0.31                  | +0.02                   |
| 4세대        | 0.30                  | -0.01                   |

\*가상의 p 값을 설정하여  $N_e$  추정

# 분산 기반 $N_e$ 추정

## 3. 세대별 변화량 $\Delta p$ 계산

각 세대 사이의 변화량:

$$\Delta p_0 = p_1 - p_0 = 0.32 - 0.30 = +0.02$$

$$\Delta p_1 = p_2 - p_1 = 0.29 - 0.32 = -0.03$$

$$\Delta p_2 = p_3 - p_2 = 0.31 - 0.29 = +0.02$$

$$\Delta p_3 = p_4 - p_3 = 0.30 - 0.31 = -0.01$$

그래서

$$\{\Delta p\} = \{+0.02, -0.03, +0.02, -0.01\}$$

이 네 개의 값의 표본 분산을 계산하면 (평균은 0이라 가정/계산됨):

$$\text{Var}(\Delta p) \approx 0.0006$$

\*가상의 p 값을 설정하여  $N_e$  추정

# 분산 기반 $N_e$ 추정

## 4. 평균 allele 빈도 $\bar{p}$ 계산

5세대를 평균내면

$$\bar{p} \approx \frac{0.30 + 0.32 + 0.29 + 0.31 + 0.30}{5} \approx 0.304$$

그러면

$$\bar{p}(1 - \bar{p}) \approx 0.304 \times 0.696 \approx 0.212 \text{ (대략)}$$

## 5. 분산 기반 $N_e$ 계산

이제 공식을 그대로 씁니다:

$$N_e \approx \frac{\bar{p}(1 - \bar{p})}{2 \text{ Var}(\Delta p)} = \frac{0.212}{2 \times 0.0006} = \frac{0.212}{0.0012} \approx 176$$

👉 추정된 유효집단크기  $N_e \approx 176$



\*가상의  $p$  값을 설정하여  $N_e$  추정

# $N_e$ 추정

- (참고: 인류 게놈 평균)  $N_e$  는 약 1만명

## 1. 통계유전학적 설명: "합류 시간(Coalescence Time)의 극단적 지연"

집단유전학에서 유전체 데이터를 통해  $N_e$ 를 역추정할 때 가장 기본이 되는 공식은 대립유전자 간의 유전적 다양도(다형성,  $\theta$ )야.

$$\theta = 4N_e\mu$$

- $\theta$ : 두 유전자를 무작위로 뽑았을 때 염기서열이 다를 확률 (다형성 정도)
- $\mu$ : 돌연변이율 (Mutation rate)
- $N_e$ : 추정되는 유효집단크기

### ① 일반 유전자 (Neutral)의 경우

- 인류 역사에서 발생한 유전적 부동(drift)과 병목(bottleneck)으로 인해, 보통 인간의 두 대립유전자는 과거로 거슬러 올라가면 약 10만~20만 년 전(평균  $4N_e$  세대)에 한 조상으로 합류(Coalesce)해.
- 따라서 다양도( $\theta$ )가 낮고, 이를 역산한 게놈 평균  $N_e \approx 10,000$ 이 나와.

# $N_e$ 추정

- (참고: 인류 게놈 평균)  $N_e$  는 약 1만명


## 1. 일반적인 상염색체 중립 부위 (인류 게놈 평균)

선택압을 거의 받지 않는 비암호화 영역(Intergenic/Intronic neutral regions)의 평균값이야.

- 염기 다양도 ( $\theta$  또는  $\pi$ ): 약 0.001 (서로 다른 염색체 2개를 뽑아 비교하면 1,000bp당 1개 꼴로 염기 차이 존재)
- 인간 세대당 돌연변이율 ( $\mu$ ): 약  $1.2 \times 10^{-8}$  (site당 세대당 변이율)
- $N_e$  역산:

$$N_e = \frac{\theta}{4\mu} = \frac{0.001}{4 \times (1.2 \times 10^{-8})} = \frac{10^{-3}}{4.8 \times 10^{-8}} \approx 10,400$$

..... 해석: 인류 전체의 실제 머릿수( $N$ )는 수십억 명이지만, 과거 아프리카 기원 당시 겪었던 인구 병목과 역사적 drift를 고려한 유전학적 평균 집단 크기는 약 1만 명 규모였음을 보여줘.



**Fig. 1.** A crane neck model of human demography so as to be consistent with the nucleotide diversity at both *HLA* and non-*HLA* loci.

Satta, Y., Takahata, N. (2000). Polymorphism in the *HLA* class I region. In: Kasahara, M. (eds) Major Histocompatibility Complex. Springer, Tokyo.  
[https://doi.org/10.1007/978-4-431-65868-9\\_12](https://doi.org/10.1007/978-4-431-65868-9_12)

# Summary

- 새로운 HLA 대립유전자의 운명
  - 수리적 이해 능력이 필요함
  - 키워드: 확산/고정,  $p_0, \mu, N_e, s$
  - AI 시대에는 약간의 개념 정도만 알고 있으면 됨!!

끝

제외

# Tajima's $D$

## 선택 양상에 따른 유전체 서열 변화와 Tajima's $D$

선택이 일어난 유전체 영역은 중립 상태와 다른 서열 다양성 패턴을 나타낸다. 타지마(Tajima, 1989)는 평균 뉴클레오타이드 차이 수( $\hat{\theta}_{\pi} = \pi$ )와 분리 부위 수 기반 추정량( $\hat{\theta}_S = \frac{S}{a_1}$ , 여기서  $a_1 = \sum_{i=1}^{n-1} \frac{1}{i}$ )을 비교해 중립성을 검정하는 통계량  $D$ 를 고안했다.

$$D = \frac{\pi - \frac{S}{a_1}}{\sqrt{\text{Var}(\pi - \frac{S}{a_1})}}$$

# Tajima's D


| 상태      | 통계량<br>관계                   | 유전체 내<br>변이 분포<br>특징               | 주된 작용 기전                                                                                     | 대표 사례                                         |
|---------|-----------------------------|------------------------------------|----------------------------------------------------------------------------------------------|-----------------------------------------------|
| $D = 0$ | $\pi \approx \frac{s}{a_1}$ | 중립 기대치<br>와 일치                     | Wright-Fisher 평형 상태의 순<br>수 중립 진화                                                            | 가유전자(pseudogene) 등<br>기능이 없는 비암호화 영역          |
| $D < 0$ | $\pi < \frac{s}{a_1}$       | 중간 빈도<br>변이 결핍,<br>저빈도 희귀<br>변이 과다 | <b>최근의 선택적 휩쓸림</b><br>( <b>selective sweep</b> ), 유전적 편<br>승(genetic hitchhiking), 집단<br>급팽창 | 유리한 변이가 고정된 직후<br>새 돌연변이가 유입되는 단<br>계의 유전자 영역 |
| $D > 0$ | $\pi > \frac{s}{a_1}$       | 희귀 변이<br>결핍, 중간<br>빈도 다형성<br>과다    | <b>균형선택(balancing<br/>selection)</b> , 집단 구조화 및 아<br>집단 간 격리                                 | HLA 유전자 좌위, 장기 다<br>형성 유지 영역                  |

강한 양성 선택으로 유리한 변이가 급격히 고정되면, 주변 서열이 함께 고정되는 유전적 편승이 발  
생해 전체 다양성이 소거된다(선택적 휩쓸림). 이후 새로운 변이가 1개씩 축적되면서 일시적으로 희  
귀 변이가 과다해져  $D < 0$ 이 관측된다. 반대로 이형접합자 이점을 받는 HLA 영역 등은 서로 다른  
하플로타입이 오랜 기간 공존하므로 중간 빈도 변이가 축적되어  $D > 0$ 을 나타낸다.


# Allele Frequency Spectrum (SFS)

## Tajima's D by Selection Pressures


1. SELECTIVE SWEEP  
(선택적 휩쓸림,  $D < 0$ )



2. NEUTRAL EVOLUTION  
(중립 평형,  $D \approx 0$ )



3. BALANCING SELECTION  
(균형 선택,  $D > 0$ )



# 상세 수식

- 1: 라이트-피셔 균형
- 2, 3: 교육적 목적의 시뮬레이션

```
n = 20
k = np.arange(1, n)
freq = k / n

# 1. 중립 기대치 (Standard 1/i 감쇠)
neutral_sfs = 1.0 / k
neutral_sfs = neutral_sfs / np.sum(neutral_sfs)

# 2. 선택적 휩쓸림 (초저빈도 싱글턴 과다, 중간 빈도 결핍)
sweep_sfs = 1.0 / (k**2.8)
sweep_sfs = sweep_sfs / np.sum(sweep_sfs)

# 3. 균형 선택 (중간 빈도 0.5 부근 과다, 양극단 소폭 반등)
center_peak = np.exp(-((freq - 0.5) ** 2) / (2 * (0.12**2)))
balancing_sfs = 0.7 * center_peak + 0.3 * (1.0 / k + 1.0 / (n - k))
balancing_sfs = balancing_sfs / np.sum(balancing_sfs)
```


# 책

## An Owner's Guide to the Human Genome

*An introduction to human population genetics, variation, and disease*

Jonathan K Pritchard  
Stanford University

Release 1.0: September 17, 2023



- **An Owner's Guide to the Human Genome: *an introduction to human population genetics, variation and disease***
- by Jonathan Pritchard, Stanford University
- <https://web.stanford.edu/group/pritchardlab/HGbook.html>

# 강의록


- Introductory Lectures on Stochastic Population Systems
- Donald A. Dawson
- <https://arxiv.org/abs/1705.03781>

Introductory Lectures on Stochastic Population Systems

Donald A. Dawson

*School of Mathematics and Statistics  
Carleton University  
Ottawa, Canada*

# 책 (gemini 추천)



★★★

Daniel L. Hartl & Andrew G. Clark  
Principles of Population Genetics


John H. Gillespie

Population Genetics: A Concise Guide


★★★

Rasmus Nielsen & Montgomery Slatkin

An Introduction to Population Genetics: Theory and Applications



# 책 (gemini 추천)



Sewall Wright [역사적 기념비]

Evolution and the Genetics of Populations

Warren J. Ewens

Mathematical Population Genetics

# 집단유전학 분야의 대가

- Ronald Fisher, J. B. S. Haldane, and Sewall Wright

# 집단유전학 분야의 대가

- 존 F. C. 킹먼 (John F. C. Kingman)
  - 1982년 합류 이론(The Kingman's Coalescent)을 정립
  - [https://en.wikipedia.org/wiki/Coalescent\\_theory](https://en.wikipedia.org/wiki/Coalescent_theory)
  - Kingman, J. F. C. (1982). "On the Genealogy of Large Populations". Journal of Applied Probability. 19: 27–43.
- 오타 토모코 (Tomoko Ohta, 太田朋子)
  - 기무라의 중립진화론을 발전시킨 '준중립진화론(Nearly Neutral Theory of Molecular Evolution)'을 제창
  - [https://en.wikipedia.org/wiki/Tomoko\\_Ohta](https://en.wikipedia.org/wiki/Tomoko_Ohta)
  - [https://en.wikipedia.org/wiki/Nearly\\_neutral\\_theory\\_of\\_molecular\\_evolution](https://en.wikipedia.org/wiki/Nearly_neutral_theory_of_molecular_evolution)
  - Ohta T (November 1973). "Slightly deleterious mutant substitutions in evolution". Nature. 246 (5428): 96–98.

# 집단유전학 분야의 대가

- 네이 마사토시 (Masatoshi Nei, 根井正弘)
  - 유전적 거리 측정 척도인 '네이의 유전거리(Nei's genetic distance)'와 분자계통수 구축 알고리즘인 이웃결합법(Neighbor-Joining Method, NJ)
- 리처드 르윈틴 (Richard Lewontin)
  - 연관불평형(Linkage Disequilibrium,  $D$ )의 수학적 측정법을 정리
- 워런 이웬스 (Warren Ewens)
  - '이웬스 표본 공식(Ewens's sampling formula, 1972)'

# 집단유전학 분야의 대가

- Donald A. Dawson
  - 영국 Fellow of the Royal Society (2010)
- Motoo Kimura
  - 자연선택 ↔ 무작위적 Genetic Drift & 중립 돌연변이 (중립진화론)
  - Darwin Medal (1992)
  - 영국 Foreign member of Royal Society (ForMemRS, 1993)
  - 미국 Foreign member of the National Academy of Sciences of the USA (1973)

# 집단유전학 분야의 대가

- Tajima
  - Tajima's D
  - [https://en.wikipedia.org/wiki/Fumio\\_Tajima](https://en.wikipedia.org/wiki/Fumio_Tajima)
  - 네이 마사토시(Masatoshi Nei)의 제자이자,기 무라 모토오의 중립진화론을 실제 DNA 데이터로 검증할 수 있게 무기를 쥐여준 인물이며, 존 킹먼과 더불어 합류 이론을 태동시킨 핵심 주역이야.